

2024-2026 年 AI Token 经济：个人参与者商业变现深度调研与战略情报报告

一、现状定义与市场规模

在 2024 年至 2026 年第一季度的技术演进周期中，人工智能商业化的核心计价单位已不可逆转地从传统的“软件席位订阅（SaaS License）”完成了向“计算单元消耗（Token）”的结构性转变。这一转变不仅重构了底层算力供应商与顶层应用开发者之间的利益分配机制，更催生了一个围绕 Token 分发、优化与套利的全新微观经济体。

“AI Token 经济”的当前边界定义

当下的“AI Token 经济”并非指代基于区块链的加密货币投机，而是以大语言模型（LLM）及多模态模型的数据处理基本单位（Token）为核心资产，所构建的一整套商业流转生态。截至 2026 年第一季度，这一生态的边界已被明确划分为三个核心维度。首先是基础的 API 调用计费体系，即基于输入（Prompt）与输出（Completion）的 Token 数量进行的高频微小计费（Micro-transaction）。无论是通过 **OpenAI** 获取复杂的逻辑推理，还是通过 **DeepSeek** 的接口调用获取结构化数据，均按每百万 Token（1M Tokens）为标准进行结算。其次是模型推理与微调服务（MaaS），这不仅包含基础的无状态推理调用，还延伸至使用高质量行业数据对开源模型进行监督微调（SFT）或直接偏好优化（DPO）时所消耗的训练 Token 费用与计算集群租赁费用。最后是智能体（Agentic）计算与算力 Token 化，随着自主智能体（AI Agents）在企业端的普及，Token 消耗形态已从单一的人机对话，演变为后台多智能体系统（Multi-agent Systems）之间的多轮自动化任务调度。此外，底层的 GPU 算力与网络带宽被进一步分割，并映射为可交易的计算 Token，例如在去中心化物理基础设施网络（DePIN）项目中，个人的闲置带宽与算力被整合并赋予经济价值。

全球及中国市场的 Token 消耗规模与投资数据

全球范围内的 AI 投资与 Token 消耗呈现出爆发式且极度不均衡的增长态势。根据国际数据公司（IDC）在 2025 年底发布的《全球人工智能和生成式人工智能

支出指南》以及 2026 年的追踪预测，全球人工智能总投资规模预计将在 2029 年突破 1.2 万亿美元大关 。在这一宏观背景下，智能体 AI（Agentic AI）作为 Token 消耗的绝对主力，其市场规模在 2026 年已达到 76 亿美元，并预计将以超过 40% 的复合年增长率（CAGR）在 2034 年飙升至 2360 亿美元，实现了十年内 31 倍的市场扩张 。

市场指标类别	2024 年数据基准	2025-2026 年当前状态	未来预测 (2027-2034)
全球 Agentic AI 市场规模	未单独立项统计	76 亿美元 (2026)	2360 亿美元 (2034)
中国大盘日均 Token 调用量	1000 亿 Tokens	140 万亿 Tokens (2026 Q1)	持续呈指数级上升
智能体 API 调用负载增量	基准线	企业智能体规模进入爆发期	预计增长 1000 倍 (2027)
AI 系统单次行动逻辑成本	基准线	显著下降	预计降低 87% (2027)

中国市场的表现尤为激进。**IDC** 数据显示，中国 AI 市场的投资增速稳定在 25.7%，而底层的 Token 调用量则呈现出令人瞠目的几何级数增长。从 2024 年初中国日均 Token 调用量仅为 1000 亿，跃升至 2025 年底的 100 万亿，截至 2026 年 3 月，这一数字已正式突破 140 万亿，两年内增长超千倍 。这种爆炸性增长的直接驱动力是中国企业智能体规模的全面爆发。到 2026 年，国内活跃的低代码/无代码智能体数量已达到 300 万个，这些智能体在后台全天候运行，不断生成 API 调用、消耗计算 Token 并累积云基础设施成本，导致企业级智能体的 Token 消耗年均增速超过 30 倍 。这种海量的消耗一方面促使企业寻求“Token 经济学”优化方案，另一方面也为个人参与者在算力调度、API 分发与内容工业化领域创造了空前的套利窗口。

二、直接模式：Token 中间商产业链拆解

Token 中间商（API Proxy/Reseller）是 2024 至 2026 年间现金流最充沛、验证最直接，但同时也是受平台合规政策挤压最为严重的商业模式。个人卖家通过在上游大厂与下游长尾开发者之间建立信息差、支付通道与网络联通性，从而实现利润截留。然而，单纯的“倒卖 API Key”在 2026 年已基本被封杀，个人必须掌握精细的上下游运营策略。

1. 上游获取：全球主流 Token 批发渠道与政策要求

个人卖家获取底层 Token 的渠道存在明确的分层，各渠道的资质要求、折扣率与稳定性差异极大，直接决定了中间商的利润率。

首先是云服务大厂的高稳定性代理渠道。例如通过 **Microsoft Azure AI Foundry** 获取合规的 **OpenAI** 模型以及 **Anthropic Claude 3.5/4.5** 系列模型。**Anthropic** 在与 **Microsoft** 及 **NVIDIA** 达成战略合作后，承诺在 **Azure** 购买高达 300 亿美元的算力，使得 **Azure** 成为获取高并发 **Claude** 模型的首选基础设施。然而，个人通常无法直接开设具备高并发额度的企业级 **Azure** 账户，必须通过挂靠具备“微软云解决方案提供商（CSP）”资质的顶级代理商（如 **Sherweb** 等）来间接获取服务。此外，**Azure** 为初创企业提供的免费抵扣额度通常不适用于被划定为“第三方市场产品（Third-party Marketplace Items）”的 **Claude** 模型，这极大限制了个人通过白嫖免费额度进行无本套利的空间。

其次是极具性价比的海外第三方聚合平台，这是目前个人技术开发者最青睐的上游。以 **Together AI** 和 **Fireworks AI** 为代表的聚合商，通过在 **NVIDIA Blackwell** 架构上深度优化开源模型推理堆栈，将单 Token 成本压缩至极致。以 **Together AI**

AI 为例，其调用 **Llama 3.1 70B** 进行微调的定价约为 2.90/1M Tokens，而基础

的开源模型推理更是低廉[2]。**Together AI** 针对初创企业推出了最高可达

50,000 平台额度的加速器计划（Startup Accelerator），有开发能力的个人可通过注册壳公司进行申请，从而获得海量的免费初始 Token。**Fireworks AI** 同样以极快的推理速度著称，其 **Llama 3.1 8B** 的微调费用低至 \$0.50/1M Tokens。但必须高度警惕的是，**Fireworks AI** 2026 版的最终用户服务条款（TOS）中加入了极其严苛的限制，明确标明“未经事先书面同意，禁止购买、出售或转让 API 密钥”，严禁通过自动化抓取或转售其服务。

最后是处于政策红利期的国内大厂 API 渠道。针对中国市场的合规要求，国内大模型在 2025-2026 年开启了激烈的价格战与开发者争夺战。例如，**DeepSeek** 通过超算互联网平台（**scnet.cn**）推出了“AI 生态伙伴加速计划”。对于审核通过的个人开发者，平台直接开放 32B 及以下规格的 API 接口供测试使用；若个人能包装成企业身份提交联合开发方案，甚至可申请到 1 万至 5 万卡时的算力补贴，涵盖 **DeepSeek V3/R1 API** 的调用额度。同样，**智谱 AI (Zhipu)** 通过其开放平台（**open.bigmodel.cn**）提供 **GLM-5** 系列模型的 API，针对大学生、开发者与政企客户设有不同层级的折扣包与模型战略领航班计划，是国内合规开展 Token 分销的优质上游。

2. 打包策略：个人包装售卖的具体模板

鉴于上游平台（如 **OpenAI** 与 **Fireworks AI**）对直接倒卖 API Key 的严厉打击，个人中间商必须将原始 Token 进行“服务化封装”，赋予其附加价值，以规避违规审查并提高溢价。具体而言，目前市场上跑通的打包模板主要有三种。

第一种是构建按次或按月计费的行业专属 Chatbot（套壳 SaaS）。中间商需要租用海外轻量级云服务器，部署开源的大模型应用构建框架，如 **Dify.ai** 或 **FastGPT**。在这些框架后端填入自己通过代理获取的低价 API Key，并在前端配置高度专业化的系统提示词（System Prompt）。例如，将其包装为“亚马逊跨境电商独立站文案自动化写手”，并对接 **Stripe** 或国内的聚合支付接口。下游用户完全不需要了解 API 和 Token 的概念，只需购买 49 元/月的套餐即可使用该特定功能。此模式不仅合法合规，且溢价能力远超单纯卖 Key。

第二种模板是开发会员制 AI 工具箱（常以 Chrome 浏览器插件形式存在）。个人开发者利用极少量的代码编写一款具备特定便捷功能的浏览器扩展，例如网页划词翻译、长文本一键总结或 PDF 核心要点提取。后端直接调用成本极低的旗舰模型（如 **DeepSeek-V3** 或 **Claude Haiku 4.5**）。通过这种方式，个人卖的不再是底层的 Token，而是“提升办公效率的工具箱月卡”，从而将上游按量计费的变动成本转化为下游固定收取的订阅费，利用用户使用率不足（Under-utilization）来实现套利。

第三种是接口聚合路由（API Gateway）分发。针对预算极低且没有双币信用卡的国内长尾开发者社区，个人利用 **One-API**、**New-API** 等开源网关软件，将自己搜集的海内外数十种模型 API（包括各种平台的免费试用额度）聚合为一个统一的端点（Endpoint）。随后，自行发行一套内部虚拟 Token 计费系统（例如 1 美元兑换 50 万内部 Token），允许下游开发者通过支付宝充值。****此模式需要明确的合规警告：****在中国境内为未经网信办备案的海外大模型提供商业化访问接口，属于极高风险的违法行为，极易面临行政处罚甚至刑事责任。

3. 下游获客渠道分析与转化率特征

个人卖家需要精准定位那些存在 API 调用需求但受限于支付手段、技术门槛或企业采购流程的客户群体。

在国内市场，开发者社区与技术论坛是首要阵地。**V2EX**、**掘金 (Juejin)**以及 **GitHub** 的中文 Issue 讨论区汇聚了大量独立开发者。在这些渠道获客的转化率较高，因为受众痛点明确，但这一群体的客户极为挑剔，他们具备技术比价能力，主要比拼的是接口的高并发延迟（Latency）以及单位 Token 的价格。

另一个流量巨大的渠道是主流电商与二手交易平台，如**淘宝**和**闲鱼 (Xianyu)**。用户通过搜索“AI 接口测试”、“大模型开发者账户”等关键词进入。这类渠道流量极大，但客单价极低（通常在几元至几十元之间），客户售后成本高昂。更关键的是，合规风险极大，平台随时会根据监管要求以“违规商品”或“未经安全评估的 AI 产品”名义下架商品并封禁店铺。

对于追求稳定和高客单价的卖家，海外独立开发者渠道和 SaaS 软件市场是更为优质的选择。通过在 **Gumroad**、**BuyMeACoffee** 甚至 **Product Hunt** 上发布带有一定额度 API 调用的“AI Productivity Template”（AI 生产力模板），可以直接面向拥有强劲支付能力的全球受众。这些渠道不仅合规风险极低，而且客户对于 SaaS 月租模式的接受度极高，转化率通常能稳定在浏览量的 3%至 5%之间。

4. 启动成本、定价策略与收入预期

开展 Token 中间商业业务的最低资金门槛极低，通常小于 1000 元人民币。初期只需购置一台海外轻量应用服务器（如**阿里云国际站**或 **Vultr**，成本约 50 元/月），注册一个海外域名（约 60 元/年），以及向上游 API 平台预存首批调用费用（约 500 元）。

在定价策略上，由于中间商承担了支付结算的渠道费、网络连通性的技术成本以及账号被封禁的损耗风险，通常采用成本价的 1.5 倍至 3 倍进行溢价售卖。为了迎合长尾用户，常见的手法是采用“小额高频”策略，例如将复杂的模型计费简化为“9.9 元/100 万 Token 混合包”。

根据 2026 年第一季度的行业平均水平，兼职起步的个人通过社区引流，月收入区间参考在 2000 元至 5000 元人民币。而那些成功建立私域流量、积累了数十家稳定调用 API 的小微企业客户的全职从业者，月收入可稳定在 3 万至 10 万元人民币。然而，这一模式的致命风险点在于上游平台严苛的风控体系，一旦被判定为违规转售，API Key 将被立即封禁且预存资金清零；同时，若未做好后端的高防策略，极易遭受下游恶意竞争者的 DDoS 攻击，导致账户内充值的 Token 额度在几小时内被恶意刷空。

三、衍生商业模式矩阵

除纯粹的 Token 倒卖外，基于 AI API 衍生出的应用与服务模式才是个人参与者构建长期护城河的研究重点。以下根据技术栈与资本属性，将这些已验证的商业模式分为四层。

A. 基础设施套利层

模式名称	启动资金	技能门槛	收入天花板	风险等级
算力与 Token 价差套利	1000-5000 元	中高（需懂逆向与自动化）	2 万-5 万元/月	中高（封号风险极高）

第一步具体做什么：该模式的核心在于利用不同商业平台的计费策略差异进行套利。例如，面向 C 端的聚合平台 **Poe** 采用每月 20 美元的固定订阅费，提供极大量的 **Claude Opus 4.1** 或其他顶级模型的调用配额。个人开发者利用自动化框架或协议逆向技术，将这种包月订阅制的无限量或高限额，封装还原为标准

的 API 接口格式。 **去哪里找资源/客户**：上游资源直接来源于使用海外信用卡批量注册的 C 端订阅制服务账号。下游客户主要通过 **Discord** 开发者群组、私域微信技术交流群进行隐秘对接，目标群体是那些进行大规模数据清洗但预算不足以调用官方昂贵 API 的小微数据团队。 **需要多少启动成本**：主要成本是多个订阅账号的月租以及海外代理 IP 池的费用，通常在 1000 至 5000 元人民币。 **收入模型是什么**：利用时间差和普通 C 端用户无法耗尽的闲置配额套现。按实际消耗 Token 向下游收费（价格通常设定为官方 API 价格的 30%），从而将固定月租转化为高额的计件收入。 **风险点在哪**：这是典型的违反平台最终用户许可协议（EULA）的行为。官方的反作弊与风控系统（如请求频率限制、IP 溯源）极其严格，导致这类“逆向账号”的存活率极低，随时面临大批量封号的风险，极易引发客户退款纠纷。

模式名称	启动资金	技能门槛	收入天花板	风险等级
模型微调即服务 (FaaS)	0-2000 元	高 (需懂 Python 与模型架构)	5 万-15 万元/项目	低

第一步具体做什么：在 2026 年，随着工具链的成熟，微调大模型的门槛已大幅降低。个人需熟练掌握开源生态中的微调工具箱，为特定行业（如跨境电商客服、区域性法律诊所）提供私有化模型的微调服务。核心工作是收集客户的私有数据，进行结构化清洗，随后使用 **LLaMA-Factory**（专为 Llama 架构优化的全栈微调平台）或 **Unsloth**（支持 GRPO 强化学习与高效内存管理的工具）对开源基础模型进行训练。 **去哪里找资源/客户**：客户获取渠道主要依赖高端自由职业平台如 **Upwork**、**Fiverr**，或国内的**猪八戒网**、各类行业商会微信群。在算力资源方面，个人无需斥巨资购买昂贵的 A100 或 H100 显卡，而是通过 **Google Colab Pro**（约 10/月）进行基础调试，随后在***Vast.ai***等去中心化算力平台租赁

GPU（如租用 A10G 仅需 1.10/小时）完成全量训练。 **需要多少启动成本**：启动资金极低，主要为测试期的云算力租赁与存储费用。例如，在 **Fireworks AI** 上进行 Serverless 微调，成本仅为\$0.50/1M Tokens，单次训练成本常低于 10 美元；若使用 AWS S3 长期存储模型权重，单项目每月仅需十余美元。 **收入模型是什么**：采用“项目制”接单，服务范畴涵盖数据清洗、微调训练到最终的接口部署。当前市场上一个垂直行业的定制化微调项目，市价普遍在 1 万至 5 万元人民币之间，且伴随后期的模型维护年费。由于实际算力成本极低，该模式的毛利率极高。 **风险点在哪**：企业提供的原始训练数据往往包含未脱敏的商业机密（如客户交易流水、未公开诉状），一旦在个人云环境中发生数据泄露，将面临严峻的违约责任与法律诉讼。必须签署严格的保密协议（NDA）并确保使用完毕后彻底销毁云端临时数据。

B. 应用层

模式名称	启动资金	技能门槛	收入天花板	风险等级
AI 微型 SaaS 开发	500-2000 元	中（全栈开发或无代码工	10 万-50 万元/月	低

模式名称	启动资金	技能门槛	收入天花板	风险等级
(Micro-SaaS)		具)		

第一步具体做什么：放弃大而全的平台梦，寻找极度垂直甚至略显枯燥的细分场景，构建只解决单一高频痛点的微型 AI 工具。例如，开发一款“Shopify 电商竞品评价自动提取与情感分析器”或“长篇法律判决书一键总结器”。核心机制是通过简单的 UI 界面接收用户输入，后端调用高智价优的 API（如 **GPT-4o-mini**、**Gemini 2.0 Flash** 或 **DeepSeek-V3**）处理文本，并将结构化结果返回给用户。

去哪里找资源/客户：海外发布的首发阵地必须是 **Product Hunt**、**Hacker News**，并在初期可通过 **AppSumo** 进行终身买断版（LTD）的特卖以回笼研发资金。国内则通过**微信小程序**矩阵拦截搜索流量，或在**少数派 (sspai)** 等高质量数字消费社区发布实操软文引流。根据独立黑客（Indie Hackers）社区的报告，像 SimpleAnalytics 和 Closet Tools 这样专注垂直痛点的微型 SaaS，分别达到了 40K 的月经常性收入（MRR）和 200K 的年经常性收入（ARR）。 **需要多少**

启动成本：前期成本极低。通过 **Supabase** 提供后端数据库支持，使用 **Vercel** 免费部署前端，唯一的硬性支出是购买特定垂直域名的费用（约 100 元人民币）以及随用户量增长的 API 账单。 **收入模型是什么：**经典的 SaaS 订阅制

（Subscription Model），根据功能深浅设定每月 9.99 至 49.99 不等的阶梯资费。一旦跨过盈亏平衡点，边际成本将急剧递减。 **风险点在哪：**微型 SaaS 的防御壁垒极低（Moat-less）。在 AI 代码辅助生成工具（如 **Cursor**）普及的 2026 年，任何被市场验证赚钱的创意，都会在几周内被涌现的几十个仿制品“像素级克隆”。个人开发者必须拼执行速度和私域用户运营能力。

模式名称	启动资金	技能门槛	收入天花板	风险等级
AI 内容工业化批量变现	1000-3000 元	低（懂 SEO 及工具链拼接）	5 万-10 万元/月	低

第一步具体做什么：建立基于大模型的全自动化内容流水线（Programmatic SEO）。抛弃手工写文的低效模式，利用 API 根据预设的长尾关键词矩阵，批量生成成百上千篇高度针对性的落地页文章、短视频脚本文案或电商详情页。

去哪里找资源/客户：目标客户是极度渴求流量但无力承担庞大内容团队的传统外贸 B2B 老板或跨境电商 B2C 卖家。案例表明，某澳洲 B2C 服务企业通过实施 AI SEO 战略，在 11 个月内将自然搜索带来的收益激增了 770 万美元。个人从业者可将此类案例作为背书，在各种出海营销微信群、行业线下展会中寻找代运营客户。

需要多少启动成本：核心支出在于工具链的订阅。需购买 **Ahrefs** 或 **Semrush** 挖掘长尾关键词，使用自动化集成平台 **Make** 或 **Zapier** 串联流程，最后对接 **OpenAI API** 或价格更低的国内大模型生成内容，并自动发布至客户的 **WordPress** 后台。工具总订阅费用每月在 1000 至 3000 元人民币之间。

收入模型是什么：常见的变现方式为按月收取代运营维护费（如每月收取 5000 至 10000 元，承诺生成并维护数千个长尾词页面）。更激进的做法是个人自建站群矩阵，通过布局细分 Niche 市场，利用庞大的 AI 内容获取自然流量，进而通过 **Google AdSense** 或联盟营销（Affiliate）分成变现。

风险点在哪：全球主流搜

索引引擎（尤其是 Google 的 Helpful Content Update 及后续算法调整）正在利用更高级的 AI 识别技术对纯粹拼凑、缺乏深度的低质量 AI 生成内容进行算法降权甚至直接从索引中剔除。如果未能掌握高级的结构化提示词技巧以提升内容质量，建立的流量帝国可能在一夜之间流量归零。

C. 服务层

模式名称	启动资金	技能门槛	收入天花板	风险等级
提示词工程 (Prompt) 咨询	0 元	高（深厚业务理解与系统架构）	3 万-8 万元/月	低

第一步具体做什么：随着企业智能体（AI Agents）的广泛部署，低效、冗长的提示词不仅会导致 AI 输出质量低下，更会因为多轮对话累积而吞噬海量的 Token 额度。你的任务是介入企业的 AI workflow，通过设计结构化的提示模式（如思维链 Chain of Thought、少样本提示 Few-shot Prompting），并结合云厂商的上下文缓存（Prompt Caching）技术，为企业显著降低 API 账单。

去哪里找资源/客户：目标客户多为正在进行数字化转型的中型企业 IT 部门或初创 SaaS 公司。获客渠道主要通过**在 LinkedIn (领英)发布深度的数据优化案例分析，或在高端智库平台（如在行、GLG 格理集团）注册成为行业专家，承接企业咨询。**

需要多少启动成本：典型的轻资产脑力密集型服务，启动资金几乎为零。

收入模型是什么：按小时收取高昂的专家咨询费。根据 2026 年市场报价数据，具备设计小型 Agent 系统能力的中级工程师时薪在\$75-150 之间，而能够处理高风险应用场景并提供明确 ROI 证明的高级提示词专家，其咨询费可达 250-\$400+/小时。企业极乐意买单，因为优化后的提示词架构每月能为它们省下数千美元的计算成本。

风险点在哪：这项业务的生命周期面临严峻的底层技术挑战。随着模型推理能力的代际跃升（例如具备自我反思与内建强化学习机制的推流模型），AI 对人类精雕细琢的提示词依赖度正逐渐降低，纯靠“调教话术”的咨询需求可能在未来 1-2 年内快速萎缩。

模式名称	启动资金	技能门槛	收入天花板	风险等级
AI 实战培训与知识付费	<500 元	中（重在转化文案与营销包装）	10 万-30 万元/月	低

第一步具体做什么：在铺天盖地的“AI 取代人类”的媒体渲染下，大量非技术背景的职场人群（如行政、设计、传统 HR）陷入了深度的职业焦虑。个人从业者需将复杂的 API 调用、本地化部署等技术术语，降维拆解为通俗易懂的实操教程，例如制作“普通文员如何利用 DeepSeek 和 Claude 实现 Excel 自动化与降本增效”的系列视频课程。

去哪里找资源/客户：利用短视频平台（抖音、视频号）和图文平台（小红书）的算法分发机制，发布“AI 提效神技”等钩子内容进行公域引流。随后将流量沉淀至高客单价的私域平台，如**微信公众号或知识星球**。

需要多少启动成本：几百元的屏幕录制软件订阅与麦克风设备即可起步。

收入模

型是什么：建立阶梯式的变现漏斗。前端通过 9.9 元或 199 元的录播课筛选意向用户，中端收取数百元的**知识星球**年费提供日常答疑，后端则兜售高达 3980 元至 9800 元的“高阶闭门陪跑营”或“AI 副业变现实战班”。**风险点在哪：**AI 行业的技术迭代速度令人发指，今天录制完毕并上架的实操教程，下周可能就因为大厂 API 接口改版或产品下线而彻底失效。这种内容的高速贬值极易导致大量学员退款与客诉纠纷，损害个人 IP 信誉。

D. 新兴/灰色地带（高风险警示区）

模式名称	启动资金	技能门槛	收入天花板	风险等级
账号共享与拼车服务	1000-2000 元	低	1 万-2 万元/月	极高

第一步具体做什么：在需求端，大量国内用户希望使用顶级的海外 AI 产品但无力承担高昂的单月订阅费；在供给端，个人购买合法的 Midjourney Pro 版或 ChatGPT Plus 企业版账号。随后，利用开源的第三方分发前端（或反向代理工具），将一个高价账号的会话凭证（Session/Cookie）池化，让数十个用户实现“拼车”共享。**去哪里找资源/客户：**由于属于灰色产业，主要在**淘宝、闲鱼**以及独立搭建、无需实名的发卡网（如使用**知字发卡**等开源系统）进行售卖。**需要多少启动成本：**垫付初期多个海外官方账号的订阅费用，以及购买用于规避风控的海外干净 IP（住宅代理）。**收入模型是什么：**赚取夸张的差价。例如官方月租 20 美元的账号，转手以 30 元人民币/月的价格卖给 30 个用户使用，单号月毛利即可达近 700 元。通过矩阵化运营数百个账号实现暴利。**风险点在哪：****极高的法律与资金双重风险。**首先，这严重违反了所有 AI 平台“严禁共享与转售账号”的服务条款，一旦触发风控，官方将进行批量封号且绝不退款；其次，在中国境内为公众提供未备案的境外生成式 AI 直接交互通道，属于违规开展电信增值业务，极易被相关部门立案查处。

模式名称	启动资金	技能门槛	收入天花板	风险等级
算力代币化 /DePIN 项目参与	>5000 元（重资产）	中（需懂钱包与基础硬件维护）	随加密货币价格剧烈波动	中高

第一步具体做什么：深度参与去中心化物理基础设施网络（DePIN）。这本质上是 AI 时代的“算力下乡”运动，利用分布式网络收集零散算力服务于庞大的 AI 算力缺口。以 2024-2025 年火爆的 Grass (GRASS)项目为例，该项目旨在通过用户设备的闲置带宽抓取公共网络数据，用于 AI 模型的训练与上下文检索。个人只需在不同 IP 环境下的电脑或手机中下载并运行 Grass App，保持网络在线即可充当工作节点。若寻求更高收益，则需购置高性能显卡（如 RTX 4090 集群），接入 **lo.net** 或 **Aethir** 网络出租 GPU 算力。**去哪里找资源/客户：**作为网络节点提供方，无需自行寻找终端客户，直接面向协议网络。注册 **Grass.io** 或 **Aethir** 官网，完成节点配置并连接网络即可开始计算贡献。**需要多少启动成本：**如果仅参与带宽共享（如 Grass），成本仅为现有的宽带费与设备折旧；如果是专业

级 GPU 节点（如 Aethir），则需投入数万至数十万元人民币购置硬件。

收入模型是什么：通过提供网络资源获得协议代币的空投或定期发放。例如，Grass 网络在 2025 年验证了高达 3300 万美元的真实企业收入，并在完成 1000 万美元融资后持续扩张其数据基础设施。Aethir 则在 2025 年实现了超 1.27 亿美元的年收入。Reddit 社区验证数据显示，个人用户运行 Grass 节点到 2026 年的 Epoch 17 阶段，单台移动端设备（享有 3 倍积分加成）在 12 天内可获取约 5 万积分，这些积分将在后续阶段按比例转化为 GRASS 代币。这些代币随后可在 OKX 等主流加密货币交易所出售变现法币。

风险点在哪：收益存在极高的市场波动性风险。DePIN 项目的代币价格受整体加密市场情绪及代币解锁周期（如 GRASS 曾面临高达 1.8 亿枚代币的集中解锁抛压）影响巨大，可能导致预期收益瞬间缩水。此外，在中国境内，全面禁止涉及法定货币与加密货币相互兑换的交易业务，参与此类项目变现存在极高的政策性合规风险。

四、个人路径决策树

AI Token 经济的参与路径并非一成不变，为便于读者根据自身当前的资源禀赋找到最快、胜率最高的商业化变现路径，以下提供基于四个维度的决策逻辑：

•

维度一：技术能力（能否驾驭代码架构）

-
1.
会编程（具备 Python/Node.js 全栈能力）：应坚决避开红海的内容生产，直接切入【微型 SaaS 开发】或【模型微调即服务】。作为技术人员，利用低成本 API 与开源工具链构建拥有一定技术壁垒的自动化工具或定制化微调方案，享受技术的复利效应，这是护城河最深的发展方向。
 - 2.
 3.
不会编程（纯业务背景或营销人员）：切入【AI 内容工业化】或【AI 实战培训与知识付费】。无需强求学习底层代码，利用高度成熟的无代码工作流工具（如 Make、Coze）和成熟的开源前端，将全部精力倾注于“深刻理解客户业务痛点”与“流量转化漏斗的设计”上。
 - 4.
-

维度二：资金储备（抗风险弹药量）

-

- 1.

<1000 元（极轻资产起步）：聚焦【提示词工程咨询】或【微型 Chrome 插件开发】。利用纯脑力劳动换取服务费，或利用免费的云开发平台白嫖前期资源，实现零成本试错。

- 2.

- 3.

1 万-5 万元（可支撑中等规模试水）：适合开展合规的【Token 中间商分销（套壳 SaaS）】或【程序化 SEO 站群建设】。利用这笔资金购买稳定的海外高防服务器、注册合规的海外壳公司，并进行早期的精准流量投放测试。

- 4.

- 5.

>5 万元（重资产运营空间）：可以跨越轻量级应用，直接下场投资物理硬件资源。购买顶级商用 GPU 集群参与【DePIN 算力节点（Aethir 等网络）】，或在本地搭建私有算力机房，专门为对数据安全极度敏感的传统企业客户提供完全本地化的【模型微调与私有化部署】服务。

- 6.

-

维度三：时间投入（时间约束条件）

-

- 1.

每天仅有 1 小时（寻求“睡后收入”）：选择【Grass 带宽挂机收益】或开发【单功能买断制工具】。核心在于“部署完即走”，系统在云端全天候自动运行并结算，最大程度降低后续的人工干预与客户服务成本。

- 2.

- 3.

每天 4 小时（高强度的副业拓展）：利用下班时间在 Upwork 等平台进行【按量付费代接单】。承担那些大企业不愿做、小企业做不

了的脏活累活，如海量行业数据的结构化清洗、高级别提示词优化测试等。

- 4.
- 5.

全职 All-In（事业型投入）：成立专注垂直领域的微型工作室，深耕【垂直行业微调即服务】；或者投入大量精力打通云厂商繁杂的认证体系，成为合法的【国内大厂 API（DeepSeek/智谱）区域代理分销商】，承接地方政企的 AI 采购预算。

- 6.

•

维度四：风险承受能力

•

- 1.

保守型：远离一切涉及加密货币和未备案海外模型的业务，死磕国内合规的【大模型应用开发】或【AI 企业内部培训】。

- 2.
- 3.

激进型：在明确知悉法律风险的前提下（且自身身处海外对口管辖区），参与高波动的【算力 Token 化套利】或高频的【API 跨境路由分发】。

- 4.

五、实操清单（Checklist）

为确保这份情报报告具备立竿见影的指导意义，针对两种最具普适性的推荐模式提供具体的冷启动执行清单。

推荐路径 A：微型 SaaS 开发者（副业变现，技术型）

•

本周可执行的第一步动作：立刻停止宏大的构思。在自身日常工作中寻找一个高度繁琐且必须重复执行的具体痛点（例如：每天需将上百封非结构

化的跨境电商外文邮件提炼并录入表格），使用开源的 **Dify.ai** 可视化编排界面，花 2 小时搭建一个只做这一件事的 AI 处理逻辑原型并跑通。

-
-

必须注册的 3 个关键平台/工具：

-

1.

Vercel：全球最快、最稳定的免费 Serverless 前端部署平台。

2.

3.

Together AI 或 **DeepSeek 开放平台**：获取业界目前推理成本最低的顶级智力 API，用于后端处理逻辑。

4.

5.

Product Hunt：用于全球新产品首发，积攒关键的第一批海外种子用户。

6.

-

必须避免的 2 个常见陷阱：

-

1.

痴迷于堆砌全能功能：对于独立开发者的第一版产品而言，界面上超过一个核心按钮就是失败。必须做到极度克制。

2.

3.

选错致命的支付网关：国内个人难以直接申请 **Stripe**，如果在开发完所有代码后才发现无法收款，将造成巨大挫折。需及早寻找合规代办机构，或使用门槛较低、支持部分个人收款的聚合支付平台（如寻觅 **Lemon Squeezy** 被收购后的替代品）。

4.

推荐路径 B：垂直领域模型微调服务商（全职创业，资源导向型）

-

本周可执行的第一步动作：无需购买任何昂贵硬件。在本地电脑或云环境中，从 **GitHub** 克隆 **LLaMA-Factory** 仓库。从公开渠道下载一个包含几千条数据的小型电商客服数据集，照着文档完成一次完整的基于 **Llama 3.1 8B** 的 LoRA 轻量化微调，感受全流程。

-

-

必须注册的 3 个关键平台/工具：

-

- 1.

Hugging Face：作为 AI 界的 GitHub，获取各类开源基础模型的权重文件与庞大的开源数据集。

- 2.

- 3.

Vast.ai 或 **Google Colab Pro：**以极低的按小时计费模式租用云端 GPU 算力，用于高强度的训练阶段。

- 4.

- 5.

Upwork 或 **在行：**创建专业的 Freelancer 专家账号，上架“Custom LLM Fine-tuning for E-commerce / Legal”等垂直服务包。

- 6.

-

必须避免的 2 个常见陷阱：

-

- 1.

过度向客户承诺“绝对准确率”：必须向客户明确，微调 (Fine-tuning) 主要是为了改变模型输出的特定语气、格式和特定领域的知识倾向，它无法从根本上消除大语言模型的“幻觉 (Hallucination)”痼疾。绝不能在合同中承诺 AI 能达到 100% 的事实无误。

2.

3.

无视数据清洗的“数据污染”：如果直接使用客户扔过来的未经筛选、包含大量噪音的原始脏数据进行训练，必然导致“垃圾进，垃圾出 (Garbage in, garbage out)”，最终交付的模型甚至不如未微调的基础模型聪明。数据清洗工作必须占据整个项目 70% 的时间。

4.

六、案例库

为进一步验证上述商业逻辑在 2024-2026 年周期的现实可行性，以下提供 4 个已通过实际财务验证的真实案例（关键个人信息已做匿名化处理）。

案例 1：跨境电商 AI 内容引擎 (AI 内容工业化)

•

个人背景：前亚马逊资深运营，完全不懂代码编程，启动资金储备在 1 万元人民币以内。

•

•

选择的模式：AI 内容工业化（程序化 SEO 建站网络）。

•

•

启动过程：他敏锐地发现，在特定的小语种市场（如中东、拉美）的电商独立站中，极度缺乏深度本地化且符合 Google 最新 SEO 逻辑的商品长篇导购文章。他无需编写代码，而是利用自动化工具 **Make.com** 构建了一条流水线：先用 **Ahrefs** 抓取高转化率的长尾搜索词，导入工作流后，自动调用 **Claude 3.5 Haiku** 的 API 批量生成带有特定 HTML 排版标签的高质量购买指南博客，最后通过 Webhook 自动推送到其 **Shopify** 站点的后台发布。

•

•

当前收入规模与耗时: 目前他个人独立运营着 5 个垂直品类(如户外渔具、特种 LED 灯) 的独立站, 完全依靠长尾 SEO 流量导入主站卖货, 同时辅以部分 Google AdSense 广告分成, **月净利润稳定在 6 万元人民币以上**。由于整套系统高度自动化, 他每天仅需花费不到 1 小时检查 Make 的运行报错日志。

•

案例 2: 垂直法律文书生成器 (微型 SaaS 开发)

•

个人背景: 国内某大厂全栈开发工程师 (以副业身份运作), 启动资金储备仅为购买一个冷门后缀域名的几十元。

•

•

选择的模式: Chrome 浏览器插件与微型 SaaS 结合。

•

•

启动过程: 在与律师朋友的交流中, 他发现律师群体经常需要耗费数小时将复杂的案卷口述录音转化为标准制式的法庭起诉书。他耗时一周, 利用 Next.js 快速开发了一款极简的 Web 端工具。其核心后段接入了 **DeepSeek V3 API**, 原因在于该模型在 2026 年初展现出了极强的中文逻辑推理与超长上下文 (Context Window) 处理能力, 且 API 调用价格仅为海外竞品的几分之一。产品上线后, 他仅通过在垂直律师微信群内分发几篇实操软文便完成了冷启动。

•

•

当前收入规模与耗时: 该产品采用纯粹的 SaaS 订阅制, 定价为 199 元/月。目前已积累了约 200 个忠实付费的律师用户, **月经常性收入 (MRR) 近 4 万元**。由于核心依靠云服务自动流转, 他现在每周仅需在周六抽出 3 小时修复偶发 Bug 和处理客服答疑。

•

案例 3: 企业内部知识库搭建顾问 (提示词与微调 FaaS 咨询)

-

个人背景：前 B 端软件产品经理，具有极强的业务抽象与沟通能力，资金储备小于 5000 元。

-

-

选择的模式：模型微调与企业智能体搭建服务。

-

-

启动过程：一家传统的重型机械制造工厂希望将厚达数千页的设备维修手册改造为可交互的 AI 问答助手。他接单后，首先利用开源的 **Dify** 框架在企业本地服务器部署了 **RAG**（检索增强生成）知识库架构。然而，通用大模型对机械领域的晦涩报错码识别极差。于是，他使用 **LLaMA-Factory** 在云端对开源的 **Qwen** 模型进行了一轮基于工厂历史维修工单的轻度监督微调（SFT）。微调后，该模型识别特定工厂术语的准确率从 60% 飙升至 95% 以上。

-

-

当前收入规模与耗时：他以纯项目制收费，单个工厂级的知识库微调与交付报价为 3.5 万元人民币。目前他已全职运作此项业务，每月可并行交付 2 至 3 个类似项目，**月均营收稳定在 10 万元左右**。

-

案例 4：分布式带宽节点挂机者（DePIN 生态参与者）

-

个人背景：在校大学生，懂得简单的代理与网络设置规则，手头有多台淘汰的闲置安卓手机与旧电脑，无任何初始资金储备。

-

-

选择的模式：DePIN 算力代币化（Grass 等节点部署）。

-

-

启动过程：在 2025 年中期，他通过社群了解到 **Grass** 项目的逻辑。深入研究机制后，他发现移动端设备在网络中享有高达 3 倍的积分收益乘数（Multiplier）。他将退役的 3 台安卓手机恢复出厂设置，全部安装 Grass App，并分别连接至学校宿舍、图书馆以及老家的不同免费 Wi-Fi 网络，实现物理级别的 IP 隔离，确保 24 小时不间断挂机。

-
-

当前收入规模与耗时：日常运维耗时趋近于 0 分钟。在经历项目的几个开发阶段（Epoch）后，系统根据其设备超高的在线时长（Uptime）发放了海量积分。按照 2026 年第一季度的交易所现价估算，他通过在 **OKX** 交易所逐步抛售分发到钱包的 GRASS 代币，**累计变现超 1.2 万元人民币**。这属于典型的利用认知差实现的纯无本套利。

-

七、合规与风险提示

在狂飙突进的 AI Token 经济中，个人从业者发掘出的暴利模式往往紧贴甚至越过合规红线。尤其进入 2025 至 2026 年，国内 AI 领域的监管已正式从“原则性引导”步入严厉的“实质性执法”阶段。为了确保商业模式的长期存续，个人参与者必须对以下三大风险板块保持绝对的敬畏。

1. 中国境内的法律边界与执法现状

-

严禁非法提供跨境联网服务（俗称 VPN 相关）：国内个人如果为了向下游国内客户提供直连 **OpenAI、Anthropic** 等未在国内备案的海外原生大模型服务，而在境内物理服务器上搭建带有“翻墙（Bypass Firewall）”性质的 API 代理通道并进行牟利，这种行为不仅面临行政处罚，更可能直接触犯《中华人民共和国刑法》中规定的“提供侵入、非法控制计算机信息系统程序、工具罪”。

-
-

生成式人工智能服务合规的红线：根据早已施行的《生成式人工智能服务管理暂行办法》，在中国境内面向公众提供 AI 交互服务（包括网站、小程序、SaaS 服务），其背后调用的底层大语言模型**必须已完成网信办的算法备案**。这意味着，直接利用海外未备案模型“套壳”并面向国内 C 端网民收费，属于明确的违规行为。据权威合规机构统计，自 2025 年下

半年起，国内针对 AI 领域违规行为的行政处罚案例数量环比激增 340%，单起案件的罚款金额中位数已攀升至 28 万元人民币，最高甚至超过 500 万元。

-
-

战略应对建议：若目标市场在国内，个人中间商或 SaaS 开发者**必须且只能**接入已通过备案的国内大厂合规 API（如**通义千问、智谱 GLM、DeepSeek**）。若商业模式极度依赖海外特定模型（如 Claude）的推理能力，则必须在服务器物理位置、支付渠道、公司注册架构上进行彻底的切割与隔离，全面转向“出海（Go Global）”战略，仅面向海外本地用户开展商业活动。

-

2. 主流模型厂商的商业政策限制 (ToS) 与风控打压

-

坚决禁止“直接转售”与“API 白嫖”：以 **Fireworks AI** 与 **Together AI** 为代表的海外高性价比算力提供商，在其服务条款中均明确规定：禁止对接口进行非自动化的“抓取”，更明确禁止未经官方书面同意的“购买、出售、许可或转售（Resell）API 密钥”。**OpenAI** 在其于 2026 年生效的最新商业服务条款中也清晰界定，其 API 主要提供给企业和开发者用于构建拥有实质附加功能的应用，严禁将 API 的原生计算能力不做任何加工直接包装成 Token 差价进行二次售卖。

-
-

云厂商的高压封号与资金冻结策略：云平台的风控系统极为敏锐。一旦系统监控到某个开发者账号关联的 IP 发出的 API 请求在极短时间内呈现出“大量来源各异的并发请求（典型的聚合网关分发特征）”，且伴随频繁更换的支付信用卡，系统将立即触发阻断机制，直接永久封禁该开发者账号，且预存账户内的充值余额将被全数冻结或没收，导致中间商瞬间血本无归。

-

3. 数据隐私安全与训练语料侵权红线

-

模型训练数据的污染与知识产权侵权：个人开发者在接单开展“模型微调即服务（FaaS）”或构建大规模内容生成的 RAG 系统时，如果为了提升模型表现，未经版权方明确授权，擅自爬取受国际版权法保护的专业书籍、付费行业报告或受保护的新闻文章用于模型的监督微调并进行商业牟利，极易遭遇极其高昂的国际版权巨额索赔诉讼。

-
-

敏感数据绝对禁止出境的铁律：在服务国内企业客户时，企业交付的用作微调或分析的原始数据（往往包含极其敏感的医疗病历档案、金融交易流水、未公开招标书等）绝不可通过任何 API 通道上传至境外的服务器（如 OpenAI 的美国节点）。个人开发者必须使用本地私有化部署的开源模型（Local Deployment），或者严格使用国内合规云厂商提供的加密处理服务。否则，一旦造成重要数据出境泄露，将面临包括《数据安全法》与《个人信息保护法》在内的极其严厉的法律制裁与刑事追责。

-

[Report unsafe contentOpens in a new window](#)